

**Especificación automatizada en descubrimiento causal mediante el enfoque genético:
una sinergia entre algoritmos genéticos y Double Machine Learning**

*Automated specification search in causal discovery through a genetic approach: a synergy
between genetic algorithms and Double Machine Learning*

Diego Alonso Córdova Ayala

Doctorado en Ciencias e Ingeniería Estadística, Universidad Nacional de Ingeniería, Lima,
Perú

Correo: diego.cordova@dmg-pe.com

Resumen

La inferencia causal moderna exige un Grafo Acíclico Dirigido (DAG) correctamente especificado como requisito para aplicar el Modelado Causal Estructural (SCM) y estimar efectos de intervención. La especificación manual del grafo está sujeta a sesgos teóricos y los algoritmos tradicionales de descubrimiento causal degradan su desempeño cuando crece el número de variables. Este trabajo evalúa la eficacia de un algoritmo genético (AG) basado en ordenamientos para automatizar el descubrimiento de la estructura causal y su articulación con el Double Machine Learning (DML) en la estimación de efectos. Con la red bayesiana de referencia ALARM (37 nodos, 46 aristas) como verdad de fondo, se generaron 5 000 observaciones en cada una de 30 réplicas independientes y se recuperó la estructura mediante un AG con score gaussiano BIC, comparándolo con Hill-Climbing con el mismo score, con el algoritmo PC y con una ablación de orden aleatorio. Se usaron dos indicadores orientados a la identificación, además de las métricas estructurales convencionales: la cobertura de confusores y la contaminación del conjunto de ajuste por descendientes del tratamiento. El AG obtuvo el mejor F1 de esqueleto ($0,689 \pm 0,020$) y el SHD más bajo ($42,6 \pm 4,0$); fue el único método que recuperó el 100 % de los verdaderos confusores en todas las réplicas y el único que nunca contaminó el conjunto de ajuste, con un sesgo respecto del DAG verdadero de 0,0020 frente al 0,0123–0,0257 de sus competidores. Los tres refutadores estadísticos superaron todas las réplicas. Los resultados prueban que el enfoque genético automatiza el descubrimiento estructural que necesitan para que métodos robustos como el DML entreguen estimaciones insesgadas, cerrando el vacío de la especificación manual.

Palabras clave: descubrimiento causal; algoritmos genéticos; grafo acíclico dirigido; Double Machine Learning; modelado causal estructural.

Abstract

Modern causal inference requires a correctly specified Directed Acyclic Graph (DAG) as a prerequisite for applying the Structural Causal Model (SCM) framework and estimating intervention effects. Manual graph specification is prone to theoretical bias, and traditional causal discovery algorithms degrade as the number of variables grows. This study evaluates the effectiveness of an order-based genetic algorithm (GA) for automating causal structure discovery and its coupling with Double Machine Learning (DML) for effect estimation. Using the benchmark ALARM Bayesian network (37 nodes, 46 edges) as ground truth, 5,000 observations were simulated in each of 30 independent replications and the structure was recovered with a GA driven by a Gaussian BIC score, benchmarked against Hill-Climbing with the same score, the PC algorithm, and a random-order ablation. Beyond conventional structural metrics, two identification-oriented indicators were used: confounder coverage and contamination of the adjustment set by descendants of the treatment. The GA attained the best skeleton F1 (0.689 ± 0.020) and the lowest SHD (42.6 ± 4.0); it was the only method recovering 100 % of the true confounders across all replications and the only one that never contaminated the adjustment set, with a bias relative to the true DAG of 0.0020 versus 0.0123–0.0257 for its competitors. All three statistical refuters passed in every replication. The findings support that the genetic approach automates the structural discovery required for robust methods such as DML to deliver unbiased estimates, closing the manual-specification gap.

Keywords: causal discovery; genetic algorithms; directed acyclic graph; Double Machine Learning; structural causal model.

1. Introducción

Durante décadas, el Modelado de Ecuaciones Estructurales (SEM) se empleó bajo una perspectiva fundamentalmente confirmatoria, orientada al análisis de estructuras de covarianza y variables latentes, tradición que sigue siendo productiva en las ciencias sociales y de la administración (Sandoval-Álvarez, 2025). La inferencia causal moderna requiere del rigor del Modelado Causal Estructural (SCM), un marco formal que permite plantear supuestos no paramétricos, expresar intervenciones mediante el operador *do*, y evaluar contrafactuales (Pearl, 2009; Peters et al., 2017). Al respecto, resulta esencial especificar correctamente el Grafo Acíclico Dirigido (DAG) en el cual se va a aplicar el SCM, puesto que de este grafo dependen tanto la identificación del estimando como la validez de los criterios de ajuste, como por ejemplo, el criterio de la puerta trasera o back door.

El problema en cuestión es que resulta complejo obtener ese grafo de dos maneras a la vez. Por un lado, el espacio de búsqueda es inmanejable: el número de DAG etiquetados sobre p variables crece superexponencialmente (Robinson, 1977), y por otro lado, la identificación de la estructura óptima bajo un score descomponible es NP-difícil (Chickering, 2002). Por otra parte, la especificación manual está sujeta a un conocimiento de dominio necesariamente incompleto, y a los sesgos teóricos del investigador a cargo. Ninguna de estas dos vías es sencilla, por un lado, los estudios de revisión del campo muestran que ningún algoritmo tiene dominio total y que la exactitud estructural se deteriora fuertemente con el ruido de medición (Constantinou et al., 2021; Kitson et al., 2023; Scanagatta et al., 2019; Scutari et al., 2019; Vowels et al., 2022), mientras que Kitson y Constantinou (2024) mostraron que muchos algoritmos ampliamente utilizados son más sensibles al orden arbitrario en que se leen las variables que al tamaño muestral o los hiperparámetros.

Los algoritmos genéticos (AG) son una vía prometedora para el primer problema. Actuando sobre una población de soluciones candidatas y aprovechando mecanismos de selección, cruce y mutación, realizan una búsqueda global que les permite escapar de los óptimos locales. La literatura confirma su utilidad, tanto en el aprendizaje de estructuras de redes bayesianas (Larrañaga et al., 1996a, 1996b; Sun & Zhou, 2022) como en el propio descubrimiento causal, incorporando conocimiento de dominio y operadores dinámicos de mutación (Mao et al., 2025), integrando restricciones flexibles y estrictas mediante hiperheurísticas (Dang et al., 2025) y automatizando la búsqueda de especificaciones en el modelado basado en compuestos (Trinchera et al., 2026).

En paralelo, la estimación de efectos ha avanzado con el Double Machine Learning, un estimador semiparamétrico de convergencia raíz- n que combina la ortogonalización de Neyman y validación cruzada para entregar efectos insesgados aún con funciones de estorbo de alta dimensión (Chernozhukov et al., 2018), y con los bosques causales y metalearners que extienden esa lógica a efectos heterogéneos (Künzel et al., 2019; Wager & Athey, 2018). Todos ellos comparten, sin embargo, una limitación decisiva: son estructuralmente “ciegos”. Sus garantías son condicionales a recibir un conjunto de ajuste válido, sin ningún mecanismo para comprobarlo.

Entre ambas líneas queda un vacío del conocimiento que pretende llenar este artículo. La literatura de descubrimiento causal evalúa sus algoritmos con métricas estructurales globales que ponderan equitativamente todas las aristas, cuando la identificación de un efecto concreto depende únicamente de la vecindad del tratamiento; casi nunca cuantifica la consecuencia estimacional del error estructural; compara métodos fuera del ciclo completo de

identificación y estimación; y normalmente reporta solo una única corrida, sin cuantificar la variabilidad entre réplicas. A esto hay que añadirle la advertencia de Reisach y otros (2021) respecto a la facilidad con que los benchmarks simulados pueden dar buenos resultados por ventajas aparentes de la construcción de los datos.

El objetivo del presente estudio es evaluar la eficacia de un algoritmo genético para automatizar el descubrimiento causal bajo los postulados del SCM, contrastando empíricamente la estructura recuperada frente a una estructura verdadera y conocida, y verificando que dicha estructura sustente una estimación causal insesgada. La contribución del estudio es triple, puesto que se articula el descubrimiento evolutivo con la estimación semiparamétrica dentro de un pipeline completo; se proponen dos métricas orientadas a la identificación, cobertura de confusores y contaminación por descendientes, que traducen el error estructural al lenguaje de la identificabilidad; y se reporta todo el desempeño como promedio y desviación estándar sobre 30 réplicas independientes, contrastado contra tres métodos de referencia. Para la cual, se emplea como banco de pruebas la red bayesiana ALARM, estándar de la literatura biomédica (Beinlich et al., 1989), en la que se estima el efecto del gasto cardíaco sobre la presión arterial registrados.

2. Materiales y métodos

2.1. Marco causal estructural e identificación

El SCM modela un sistema como un DAG en el que cada nodo representa una variable y cada arista dirigida codifica una relación causal directa. El criterio de la puerta trasera dice que un conjunto de variables Z permite identificar el efecto de un tratamiento T sobre un resultado Y cuando bloquea todas las rutas no causales entre T e Y y no incluye descendientes de T . El conjunto de padres del tratamiento en el DAG es siempre un conjunto de ajuste válido, según un resultado clásico (Pearl, 2009), propiedad de la cual este trabajo se aprovecha para derivar automáticamente los confusores a partir de la estructura descubierta sin intervención humana.

El límite de lo alcanzable es dado por la equivalencia de Markov: dos DAG que codifiquen las mismas independencias condicionales son indistinguibles usando sólo datos observacionales (Spirtes et al., 2000), y por lo tanto la orientación de algunas aristas es en principio irrecuperable. Esta frontera obliga a reportar por separado las métricas de esqueleto y las dirigidas.

2.2. Datos: la red ALARM

La red ALARM (A Logical Alarm Reduction Mechanism) es una red bayesiana de referencia en el ámbito del monitoreo médico, que está compuesta por 37 variables categóricas y 46 aristas dirigidas que codifican relaciones diagnósticas y hemodinámicas (Beinlich et al., 1989). Se tomó la estructura como verdad de fondo y se simuló 5 000 observaciones por réplica mediante muestreo directo de la distribución de probabilidad conjunta, usando la librería pgmpy. La elección de una red con parámetros publicados, en vez de datos generados ad hoc, obedece a la advertencia de Reisach et al. (2021) acerca de los artefactos de los benchmarks sintéticos.

Para aprender la estructura, las categorías se codificaron ordinalmente como enteros, la aproximación estándar que permite puntajes gaussianos escalables, y que también se ha utilizado en aplicaciones biomédicas de alta dimensión (Graafland & Gutiérrez, 2022). Se utilizó el gasto cardíaco (CO) como tratamiento y la presión arterial (BP) como resultado, variables que presentan confusores estructurales identificables en el grafo: frecuencia cardíaca (HR) y volumen sistólico (STROKEVOLUME).

2.3. Descubrimiento causal mediante algoritmo genético

Se utilizó un algoritmo genético basado en ordenamientos en la línea de Larrañaga et al. (1996a). Cada individuo es una permutación de los 37 nodos que representa un orden topológico, dado ese orden se selecciona por avidez el mejor conjunto de padres de cada nodo entre sus predecesores, garantizando la aciclicidad por construcción. Esta representación reduce el espacio de búsqueda de los grafos dirigidos posibles a los ordenamientos de nodos, y elimina el costo de reparar individuos cíclicos, que es el principal cuello de botella de las codificaciones matriciales.

La aptitud de cada individuo es la suma de las puntuaciones locales bajo una puntuación gaussiana BIC descomponible, la cual es calculada eficientemente a partir de la matriz de covarianza usando la varianza parcial conseguida por medio del complemento de Schur, eludiendo así recorrer los datos en cada evaluación. Se empleó como operador de cruce el Order Crossover que preserva la validez de las permutaciones; la mutación se realizó por intercambio de posiciones; y la selección fue por torneo con elitismo. Los parámetros fueron: población de 40 individuos, 60 generaciones, grado máximo de entrada de 4, probabilidad de cruce de 0,90, probabilidad de mutación de 0,30, torneo de tamaño 3, elitismo de 2 individuos y factor de penalización BIC de 3,5.

2.4. Métodos de referencia

El descubrimiento de estructura se ha abordado desde tres familias. Los métodos basados en restricciones eliminan adyacencias mediante pruebas de independencia condicional y luego orientan v-estructuras (Spirtes et al., 2000), con variantes que corrigen su dependencia del orden de las variables (Colombo & Maathuis, 2014). Los métodos basados en score optimizan una función penalizada sobre el espacio de DAG, ya sea de forma exacta mediante programación lineal entera (Bartlett & Cussens, 2017) o búsqueda A* con conjuntos óptimos potenciales de padres (He et al., 2023), ya sea de forma heurística mediante variantes voraces del clásico K2 (Behjati & Beigy, 2020). Las estrategias híbridas restringen primero el espacio de padres candidatos y optimizan el score dentro de él (Tsamardinos et al., 2006). El elemento común a todas ellas es la exploración local del espacio de estructuras, que las expone al estancamiento en óptimos locales.

Para aislar la contribución de la búsqueda evolutiva, el AG se contrastó contra tres competidores evaluados sobre exactamente los mismos datos. El primero es un Hill-Climbing con operadores de adición, borrado e inversión que optimiza el mismo score gaussiano BIC, de modo que cualquier diferencia sea atribuible a la estrategia de búsqueda y no a la función objetivo. Luego, se empleó el algoritmo PC con prueba de independencia condicional de Fisher-z ($\alpha = 0,01$, condición de máximo 3) representante de la familia basada en restricciones (Spirtes et al., 2000). Ahora bien, el tercero es una ablación intencionada, esto es, un decodificador de ordenamiento aleatorio con la misma selección avara de padres que comparte con el AG la representación, pero que no considera la selección, ni cruce ni mutación.

2.5. Métricas de evaluación

La estructura recuperada fue comparada con la estructura verdadera mediante la Distancia de Hamming Estructural (SHD), la cual cuenta aristas ausentes, sobrantes e invertidas, y mediante precisión, recall y F1 calculados tanto sobre las aristas dirigidas como sobre el esqueleto no dirigido.

A estos indicadores comunes se añadieron dos métricas de identificación. Por un lado, la cobertura de los confusores, que es la fracción de verdaderos padres del tratamiento que están presentes en el conjunto de ajustes estimado; un valor inferior a uno implica que hay confusión residual. Los descendientes de contaminación indican si el conjunto estimado contiene un descendiente del tratamiento, lo que genera un sesgo de colisionador o sobreajuste.

La justificación para estas métricas es directa: dos estructuras con idéntico SHD pueden ser completamente diferentes en términos de utilidad causal dependiendo de dónde se concentren sus errores, y solo los errores en la vecindad del tratamiento comprometen la identificación.

2.6. Estimación causal con Double Machine Learning

A partir del DAG recuperado, el conjunto de ajuste se derivó como los padres del tratamiento, y se estimó el Efecto Promedio del Tratamiento (ATE) mediante un DML parcialmente lineal con validación cruzada de dos particiones (Chernozhukov et al., 2018). Las funciones de estorbo -las esperanzas condicionales del resultado y del tratamiento dadas las variables de confusión- fueron aproximadas con bosques aleatorios de 100 árboles y profundidad máxima de 6, y el parámetro causal se obtuvo como la razón entre la covarianza de los residuos y la varianza del residuo del tratamiento; el error estándar procede de la varianza sándwich de la función de momentos de Neyman. También se usó como referencia el ATE con el conjunto de ajuste del DAG verdadero, el oráculo y sin ningún ajuste. La implementación refleja la lógica de la librería DoWhy (Sharma & Kiciman, 2020).

Se introdujo una salvaguarda: la variable de resultado se excluye explícitamente del conjunto de ajuste. Un método que oriente mal la arista entre tratamiento y resultado pondría a este último entre los padres del primero, y condicionar sobre el propio resultado anula la varianza residual y hace degenerar la estimación. La salvaguarda hace lo mismo que haría cualquier analista; la contaminación estructural subyacente se reporta de forma separada.

2.7. Evaluación de robustez y diseño Monte Carlo

Se usaron tres refutadores al estilo de DoWhy, cada uno con su propio criterio de aprobación. El refutador de causa común aleatoria añade un confusor irrelevante y comprueba que el efecto no varía en más de un 15 % relativo. El tratamiento de placebo intercambia el tratamiento y requiere que el efecto se colapse a cero. El de submuestra reestima con el 80% de los datos y evalúa la estabilidad.

Todo el procedimiento se repitió sobre 30 réplicas independientes, cuyas semillas proceden de una semilla maestra a través de una secuencia generadora que garantiza flujos estadísticamente independientes. Los resultados se expresan como promedio y desviación estándar de réplicas. El código completo, con externalización de hiperparámetros, fijación de semillas, registro automático del entorno y 35 tests automatizados, se entrega como repositorio público licenciado bajo MIT.

3. Resultados

3.1. Recuperación de la estructura causal

En la Tabla 1 se resumen los resultados de la recuperación estructural por método. El algoritmo genético obtuvo el mejor F1 de esqueleto ($0,689 \pm 0,020$) y el menor SHD ($42,6 \pm 4,0$), por encima del Hill-Climbing que optimiza el mismo score ($0,649 \pm 0,027$) y del PC ($0,675 \pm 0,021$), esto apunta que la ventaja no proviene de la representación por permutaciones, que comparte con el AG, sino de la búsqueda evolutiva que opera sobre ella, ya que la ablación de orden aleatorio quedó claramente rezagada ($0,591 \pm 0,029$).

La diferencia principal entre el F1 de esqueleto ($0,689$) y el dirigido ($0,535$) es coherente con la equivalencia de Markov, esto es, que la orientación de algunas aristas no se puede establecer a partir de datos meramente observados. En la corrida de referencia con semilla 42, luego de 60 generaciones, el AG convergió a una estructura con 65 aristas, de las cuales 31 coincidieron con exactitud en dirección con el DAG verdadero y 8 quedaron invertidas.

Tabla 1

Recuperación estructural por método (30 réplicas independientes).

Método	F1 esqueleto	Recall esqueleto	Precisión esqueleto	F1 dirigido	SHD
Algoritmo genético	$0,689 \pm 0,020$	$0,822 \pm 0,021$	$0,594 \pm 0,024$	$0,535 \pm 0,048$	$42,6 \pm 4,0$
Hill-Climbing (BIC)	$0,649 \pm 0,027$	$0,798 \pm 0,026$	$0,547 \pm 0,033$	$0,449 \pm 0,074$	$51,2 \pm 6,9$
PC (Fisher-z)	$0,675 \pm 0,021$	$0,806 \pm 0,021$	$0,581 \pm 0,027$	$0,472 \pm 0,026$	$46,9 \pm 2,9$
Orden aleatorio	$0,591 \pm 0,029$	$0,785 \pm 0,035$	$0,474 \pm 0,029$	$0,314 \pm 0,056$	$67,0 \pm 5,7$

Nota. Media $\pm$ desviación estándar sobre 30 réplicas. SHD = Structural Hamming Distance; valores menores indican mejor recuperación. Red ALARM (37 nodos, 46 aristas), 5 000 observaciones por réplica.

3.2. Calidad del conjunto de ajuste

En la Tabla 2 se puede observar el resultado decisivo. Fue el único método capaz de recuperar el 100% de los verdaderos confusores en todas las 30 réplicas y el único que nunca incluyó descendientes del tratamiento en el conjunto de ajuste (algoritmo genético). En

promedio, el Hill-Climbing recuperó el 70% de los confusores y contaminó el conjunto en un 6,7% de las réplicas, mientras que el PC recuperó el 65% y contaminó en un 23,3%; la ablación aleatoria contaminó en un 46,7% de los casos.

El impacto reputacional es inmediato y cuantificable, el sesgo absoluto del AG respecto del oráculo fue de 0,0020, entre seis y trece veces menor que el de sus competidores. En la corrida de referencia, el conjunto de ajuste del DAG verdadero fue {HR, STROKEVOLUME} y el del AG fue {HR, HYPOVOLEMIA, LVFAILURE, STROKEVOLUME}: el AG añadió ancestros adicionales, que no comprometen la identificación, pero capturó los dos confusores relevantes. El PC orientó erróneamente, sin embargo, la arista entre presión arterial y gasto cardíaco, incorporando el propio resultado entre los padres del tratamiento.

Tabla 2

Calidad del conjunto de ajuste y consecuencia estimacional.

Método	Cobertura de confusores	Contaminación por descendientes	Sesgo vs. oráculo
Algoritmo genético	1,000	0,0 %	0,0020
Hill-Climbing (BIC)	0,700	6,7 %	0,0123
PC (Fisher-z)	0,650	23,3 %	0,0257
Orden aleatorio	0,567	46,7 %	0,0173

Nota. La cobertura de confusores es la proporción de padres verdaderos del tratamiento presentes en el conjunto estimado. La contaminación es el porcentaje de réplicas en que el conjunto incluye algún descendiente del tratamiento. El sesgo se calcula respecto del efecto estimado con el conjunto de ajuste del DAG verdadero.

3.3. Estimación del efecto causal y robustez

Como muestra la Tabla 3, el ATE estimado con el ajuste del AG ($0,319 \pm 0,023$) coincidió con el obtenido con el DAG verdadero ($0,319 \pm 0,023$), mientras que el PC lo sobreestimó ($0,341 \pm 0,028$) al omitir un confusor relevante y el modelo sin ajuste alguno arrojó $0,325 \pm 0,013$.

Las tres pruebas de robustez respaldaron la fiabilidad del estimador basado en la estructura descubierta, aprobando en el 100 % de las réplicas. La inclusión de una variable aleatoria de efecto común no modificó el efecto ($0,315 \pm 0,023$); el tratamiento con placebo se redujo hasta

cero ($-0,001 \pm 0,012$), lo cual indica que el procedimiento no genera relaciones espurias; y la estimación repetida con el 80 % de la muestra continuó sin cambios ($0,317 \pm 0,032$). Juntos, estos resultados demuestran validez interna y resistencia al remuestreo.

Tabla 3

Estimación del efecto causal (ATE) de CO sobre BP y pruebas de robustez.


Estimación o prueba	ATE	Interpretación
Sin ajuste alguno	$0,325 \pm 0,013$	Referencia sesgada
Ajuste con el DAG verdadero (oráculo)	$0,319 \pm 0,023$	Referencia insesgada
Ajuste con el DAG del AG	$0,319 \pm 0,023$	Coincide con el oráculo
Ajuste con el DAG del Hill-Climbing	$0,310 \pm 0,030$	Sesgo moderado
Ajuste con el DAG del PC	$0,341 \pm 0,028$	Sobreestimación
Causa común aleatoria	$0,315 \pm 0,023$	Estable (aprueba 100 %)
Tratamiento placebo	$-0,001 \pm 0,012$	Colapsa a cero (aprueba 100 %)
Submuestra al 80 %	$0,317 \pm 0,032$	Estable (aprueba 100 %)

Nota. Media $\pm$ desviación estándar sobre 30 réplicas. Los refutadores se utilizan sobre el conjunto de ajuste derivado del AG.

Cabe señalar que, las Figuras 1,2 y 3 evidencian gráficamente estos hallazgos principales.

Figura 1


DAG verdadero de la red ALARM (izquierda) frente al DAG recuperado por el algoritmo genético (derecha).



Nota. Se observa grafo regenerado, donde aristas verdes coinciden con adyacencias verdaderas y rojas son falsos positivos. El tratamiento (CO) y el resultado (BP) aparecen destacados. Corrida de referencia con semilla 42.

Figura 2


F1 del esqueleto por método (media $\pm$ desviación estándar sobre 30 réplicas).



Nota. El algoritmo genético supera a los tres métodos de referencia, incluida la ablación que comparte su representación.

Figura 3

Distribución del efecto estimado por método frente al DAG verdadero.



Nota. La línea discontinua señala el efecto estimado con el conjunto de ajuste del DAG verdadero. El algoritmo genético concentra su distribución en torno a esa referencia, mientras que el PC se desplaza sistemáticamente por encima.

4. Discusión

Los resultados respaldan el argumento principal de esta tesis, a saber, que la combinación entre un algoritmo genético y el Double Machine Learning permite pasar de un análisis exploratorio a una estimación causal robusta sin depender de una especificación manual del grafo. El resultado más importante no es que la estructura se recupere perfectamente, algo imposible en presencia de equivalencia de Markov, sino que basta con una estructura aproximadamente recuperada, con un F1 de esqueleto de 0,689 y un F1 dirigido de 0,535, para que el DML tenga un efecto indistinguible del de la verdad fundamental.

Esta explicación del comportamiento es lo que a mi entender constituye el aporte conceptual del estudio. Para identificar un efecto determinado no hace falta disponer del DAG completo, basta con un conjunto de ajuste que incluya los confusores relevantes y excluya los descendientes del tratamiento. El error estructural no es homogéneo, es decir, una arista mal orientada lejos del tratamiento es prácticamente inocua, pero un confusor omitido o un descendiente incorporado compromete la identificación. Las métricas tradicionales dan el mismo peso a todas las aristas, y no ven la diferencia. La comparación entre las Tablas 1 y 2 lo muestra claramente: el PC logra un F1 de esqueleto (0,675) muy cercano al del AG (0,689) y un SHD mejor que el del Hill-Climbing, pero contamina el conjunto de ajuste en el 23,3 % de las réplicas y termina con el mayor sesgo de todos los métodos evaluados. El PC parece competitivo juzgado por el SHD; juzgado por su utilidad causal, es el peor.

Ello pone de relieve el carácter complementario de las dos partes. El DML es muy poderoso para obtener estimaciones insesgadas, pero es estructuralmente ciego: necesita que se le pase un conjunto de confusores matemáticamente válido y no tiene forma de comprobarlo. En nuevos estudios de especialidad biomédica, suponer que poseemos el DAG estructural perfecto es una ilusión, y la introducción de colisionadores o mediadores en el DML debido a un error de especificación generaría sesgos con intervalos de confianza estrechos, es decir, un error firmemente equivocado. Para ello, el AG reducirá tal riesgo descubriendo la estructura subyacente de forma automática. La constancia con los tres refutadores, y la desaparición del efecto placebo, confirman que la señal estimada es causal y no un artefacto del procedimiento.

Cabe señalar que, la aleatoria ablación hace posible una correcta distribución de los méritos. Comparte con el AG la representación por permutaciones y la decodificación avara de padres, pero no tiene selección, cruce y mutación; su F1 de esqueleto desciende hasta 0,591 y su cobertura de confusores hasta 0,567. Por tanto la ventaja observada no procede de la codificación sino de la búsqueda evolutiva que actúa sobre la misma. Esta observación conecta con la de Kitson y Constantinou (2024) desde un ángulo complementario: si el orden arbitrario

de las variables condiciona decisivamente la exactitud de los algoritmos convencionales, optimizarlo explícitamente en vez de aceptarlo como dato es una respuesta metodológicamente coherente.

Asimismo, resulta necesario señalar que el estudio tiene cuatro limitaciones principales. En primera instancia, la orientación de aristas dentro de las clases de equivalencia de Markov, que ningún método basado únicamente en datos observacionales puede resolver completamente. Trabajos recientes sugieren posibles soluciones para reducirla mediante la incorporación de conocimiento de dominio y operadores de mutación dinámicos (Mao et al., 2025), o la combinación de restricciones flexibles y estrictas mediante hiperheurísticas (Dang et al., 2025). La segunda es el empleo de una codificación ordinal de las variables categóricas con un puntaje gaussiano; los puntajes específicos para datos discretos, la influencia de los cuales en la estructura recuperada ha sido documentada (Yaman & Cengiz, 2025), o las caracterizaciones continuas de la aciclicidad (Zheng et al., 2018), podrían mejorar la precisión de la orientación. La tercera es que los resultados proceden de una red de referencia con estructura conocida, aunque el uso de parámetros publicados reduce el riesgo señalado por Reisach et al. (2021), la validación en datos reales es la extensión natural del proyecto. La cuarta es el supuesto de suficiencia causal, asumiendo que no hay confusores latentes, para levantarlo habría que trabajar con grafos ancestrales máximos.

5. Conclusiones

En cuanto a las conclusiones, este trabajo mostró de forma empírica que un algoritmo genético basado en ordenamientos puede automatizar el descubrimiento de la estructura causal con calidad suficiente como para dar soporte a una estimación causal sin sesgos mediante Double Machine Learning. En la red ALARM y en 30 réplicas independientes, el AG obtuvo mayor F1 de esqueleto ($0,689 \pm 0,020$) y menor SHD ($42,6 \pm 4,0$) entre cuatro métodos evaluados, recuperó el 100 % de los verdaderos confusores en todas las réplicas y produjo un efecto de $0,319 \pm 0,023$, coincidente con el DAG verdadero y validado por tres pruebas de robustez que aprobaron en todos los casos.

La contribución principal es conectar el descubrimiento evolutivo estructural con la robusta estimación semiparamétrica en un pipeline completo, cerrando el vacío de la especificación manual del DAG en el marco del SCM. Una contribución metodológica derivada es la propuesta de evaluar los métodos de descubrimiento causal mediante indicadores orientados a la identificación, cobertura de confusores y contaminación por descendientes, y no solo a través de métricas estructurales globales: el caso del PC, competitivo en SHD pero el peor en sesgo, muestra que ambas familias de métricas pueden ordenar los métodos de forma opuesta. En

líneas futuras, pretendemos incluir conocimiento de dominio para mejorar la orientación de aristas, emplear puntajes específicos para datos discretos, levantar el supuesto de suficiencia causal y validar en bases de datos biomédicas reales. Se publica todo el código, incluyendo semillas fijadas, hiperparámetros documentados, hardware especificado y versiones de librerías declaradas, como repositorio público para permitir la completa reproducibilidad de los resultados.

Referencias

- Bartlett, M., & Cussens, J. (2017). Integer linear programming for the Bayesian network structure learning problem. *Artificial Intelligence*, 244, 258–271. <https://doi.org/10.1016/j.artint.2015.03.003>
- Behjati, S., & Beigy, H. (2020). Improved K2 algorithm for Bayesian network structure learning. *Engineering Applications of Artificial Intelligence*, 91, 103617. <https://doi.org/10.1016/j.engappai.2020.103617>
- Beinlich, I. A., Suermondt, H. J., Chavez, R. M., & Cooper, G. F. (1989). The ALARM monitoring system: A case study with two probabilistic inference techniques for belief networks. En J. Hunter, J. Cookson & J. Wyatt (Eds.), *AIME 89* (pp. 247–256). Springer. https://doi.org/10.1007/978-3-642-93437-7_28
- Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1–C68. <https://doi.org/10.1111/ectj.12097>
- Chickering, D. M. (2002). Optimal structure identification with greedy search. *Journal of Machine Learning Research*, 3, 507–554.
- Colombo, D., & Maathuis, M. H. (2014). Order-independent constraint-based causal structure learning. *Journal of Machine Learning Research*, 15(1), 3741–3782.
- Constantinou, A. C., Kitson, N. K., Liu, Y., Chobtham, K., Hashemzadeh, A., Nanavati, P. A., Mbuva, R., & Petrungaro, B. (2023). Open problems in causal structure learning: A case study of COVID-19 in the UK. *Expert Systems with Applications*, 234, 121069. <https://doi.org/10.1016/j.eswa.2023.121069>
- Constantinou, A. C., Liu, Y., Chobtham, K., Guo, Z., & Kitson, N. K. (2021). Large-scale empirical validation of Bayesian network structure learning algorithms with noisy data. *International Journal of Approximate Reasoning*, 131, 151–188. <https://doi.org/10.1016/j.ijar.2021.01.001>
- Dang, Y., Gao, X., & Wang, Z. (2025). A novel hyper-heuristic algorithm with soft and hard constraints for causal discovery using a linear structural equation model. *Entropy*, 27(1), 38. <https://doi.org/10.3390/e27010038>
- Graafland, C. E., & Gutiérrez, J. M. (2022). Learning complex dependency structure of gene regulatory networks from high dimensional microarray data with Gaussian Bayesian networks. *Scientific Reports*, 12, 18704. <https://doi.org/10.1038/s41598-022-21957-z>

- He, C., Di, R., & Tan, X. (2023). Bayesian network structure learning using improved A* with constraints from potential optimal parent sets. *Mathematics*, 11(15), 3344. <https://doi.org/10.3390/math11153344>
- Kitson, N. K., & Constantinou, A. C. (2024). The impact of variable ordering on Bayesian network structure learning. *Data Mining and Knowledge Discovery*, 38(4), 2545–2569. <https://doi.org/10.1007/s10618-024-01044-9>
- Kitson, N. K., Constantinou, A. C., Guo, Z., Liu, Y., & Chobtham, K. (2023). A survey of Bayesian network structure learning. *Artificial Intelligence Review*, 56, 1–94. <https://doi.org/10.1007/s10462-022-10351-w>
- Künzel, S. R., Sekhon, J. S., Bickel, P. J., & Yu, B. (2019). Metalearners for estimating heterogeneous treatment effects using machine learning. *Proceedings of the National Academy of Sciences*, 116(10), 4156–4165. <https://doi.org/10.1073/pnas.1804597116>
- Larrañaga, P., Kuijpers, C. M. H., Murga, R. H., & Yurramendi, Y. (1996a). Learning Bayesian network structures by searching for the best ordering with genetic algorithms. *IEEE Transactions on Systems, Man, and Cybernetics — Part A: Systems and Humans*, 26(4), 487–493. <https://doi.org/10.1109/3468.508827>
- Larrañaga, P., Poza, M., Yurramendi, Y., Murga, R. H., & Kuijpers, C. M. H. (1996b). Structure learning of Bayesian networks by genetic algorithms: A performance analysis of control parameters. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 18(9), 912–926. <https://doi.org/10.1109/34.537345>
- Mao, T., Bu, X., Cai, C., Lu, Y., & Du, J. (2025). An improved genetic algorithm for causal discovery. *Journal of Systems Engineering and Electronics*, 36(3), 768–777. <https://doi.org/10.23919/JSEE.2025.000015>
- Pearl, J. (2009). *Causality: Models, reasoning, and inference* (2.^a ed.). Cambridge University Press. <https://doi.org/10.1017/CBO9780511803161>
- Peters, J., Janzing, D., & Schölkopf, B. (2017). *Elements of causal inference: Foundations and learning algorithms*. MIT Press.
- Reisach, A. G., Seiler, C., & Weichwald, S. (2021). Beware of the simulated DAG! Causal discovery benchmarks may be easy to game. *Advances in Neural Information Processing Systems*, 34, 27772–27784.
- Robinson, R. W. (1977). Counting unlabeled acyclic digraphs. En C. H. C. Little (Ed.), *Combinatorial Mathematics V* (pp. 28–43). Springer. <https://doi.org/10.1007/BFb0069178>

- Sandoval-Álvarez, C. (2025). Exploración de los efectos indirectos condicionales: Un enfoque de modelado de ecuaciones estructurales. *Revista de Administração Contemporânea*, 29(4), e250047. <https://doi.org/10.1590/1982-7849rac2025250047.en>
- Scanagatta, M., Salmerón, A., & Stella, F. (2019). A survey on Bayesian network structure learning from data. *Progress in Artificial Intelligence*, 8, 425–439. <https://doi.org/10.1007/s13748-019-00194-y>
- Scutari, M. (2010). Learning Bayesian networks with the bnlearn R package. *Journal of Statistical Software*, 35(3), 1–22. <https://doi.org/10.18637/jss.v035.i03>
- Scutari, M., Graafland, C. E., & Gutiérrez, J. M. (2019). Who learns better Bayesian network structures: Accuracy and speed of structure learning algorithms. *International Journal of Approximate Reasoning*, 115, 235–253. <https://doi.org/10.1016/j.ijar.2019.10.003>
- Sharma, A., & Kiciman, E. (2020). DoWhy: An end-to-end library for causal inference. *arXiv*. <https://doi.org/10.48550/arXiv.2011.04216>
- Spirtes, P., Glymour, C., & Scheines, R. (2000). *Causation, prediction, and search* (2.^a ed.). MIT Press.
- Sun, B., & Zhou, Y. (2022). Bayesian network structure learning with improved genetic algorithm. *International Journal of Intelligent Systems*, 37(9), 6023–6047. <https://doi.org/10.1002/int.22833>
- Trinchera, L., Pietropolli, G., Castelli, M., & Schuberth, F. (2026). Automated specification search for composite-based structural equation modeling: A genetic approach. *Computational Statistics & Data Analysis*, 219, 108348. <https://doi.org/10.1016/j.csda.2026.108348>
- Tsamardinos, I., Brown, L. E., & Aliferis, C. F. (2006). The max-min hill-climbing Bayesian network structure learning algorithm. *Machine Learning*, 65(1), 31–78. <https://doi.org/10.1007/s10994-006-6889-7>
- Vowels, M. J., Camgoz, N. C., & Bowden, R. (2022). D'ya like DAGs? A survey on structure learning and causal discovery. *ACM Computing Surveys*, 55(4), 82. <https://doi.org/10.1145/3527154>
- Wager, S., & Athey, S. (2018). Estimation and inference of heterogeneous treatment effects using random forests. *Journal of the American Statistical Association*, 113(523), 1228–1242. <https://doi.org/10.1080/01621459.2017.1319839>
- Yaman, A., & Cengiz, M. A. (2025). Comparative evaluation of score criteria for dynamic Bayesian network structure learning. *PLOS ONE*, 20(11), e0336250. <https://doi.org/10.1371/journal.pone.0336250>

Zheng, X., Aragam, B., Ravikumar, P., & Xing, E. P. (2018). DAGs with NO TEARS: Continuous optimization for structure learning. *Advances in Neural Information Processing Systems*, 31, 9472–9483. <https://doi.org/10.48550/arXiv.1803.01422>