



Universidad Nacional de Ingeniería
Escuela de Posgrado
Doctorado en Ciencias e Ingeniería Estadística

Especificación automatizada en descubrimiento causal mediante el enfoque genético

Sinergia entre Algoritmos Genéticos y Double Machine Learning

Diego Alonso Córdova Ayala

Agenda

1. El problema: por qué falla la especificación del grafo
2. Objetivo e hipótesis
3. Metodología
4. Resultados
5. Discusión y conclusiones
6. Reproducibilidad

El problema

El problema

- El **Modelado Causal Estructural (SCM)** exige un **grafo acíclico dirigido (DAG)** **correctamente especificado**: de él dependen la identificación del estimando y la validez del criterio de la puerta trasera.
- Su especificación manual es **frágil** y sus errores no son benignos: incorporar un colisionador o un mediador como si fuese un confusor **introduce sesgo en lugar de atenuarlo**.
- El espacio de grafos crece de forma **superexponencial** y la búsqueda de la estructura óptima es NP-difícil; los métodos clásicos se estancan en óptimos locales.
- Los estimadores semiparamétricos robustos, como el **Double Machine Learning (DML)**, permanecen condicionados a recibir un conjunto de ajuste válido, sin poder verificarlo.

Problema de investigación

No se dispone de evidencia de que un procedimiento **automatizado** de descubrimiento estructural recupere la parte del grafo que la **identificación** exige para sostener una **estimación causal insesgada**.

El vacío de conocimiento

El descubrimiento estructural y la estimación causal robusta han progresado **en paralelo**, evaluándose con criterios distintos:

Descubrimiento estructural

- Recupera el grafo completo.
- Se juzga con métricas *globales* (SHD, F1) que ponderan todas las aristas por igual.

Estimación robusta (DML)

- Estima el efecto.
- *Presupone* el grafo como dato.

Vacío de conocimiento

La literatura no evalúa si la estructura descubierta **automáticamente** es suficiente para la **identificación**, ni traduce el error estructural en su **consecuencia sobre el sesgo** del efecto estimado.

Pregunta de investigación

¿La estructura recuperada por un **algoritmo genético** basta para que el DML entregue un efecto **inesgado**?

Objetivo e hipótesis

Objetivo e hipótesis

Objetivo general

Evaluar la eficacia de un algoritmo genético (AG) para **automatizar el descubrimiento causal** bajo el SCM, verificando que la estructura recuperada sustente una estimación causal insesgada mediante DML.

Hipótesis

La especificación automatizada con AG recupera una estructura **de calidad suficiente** para que el DML produzca un efecto **estadísticamente indistinguible** del obtenido con el DAG verdadero.

Hipótesis auxiliar (el aporte)

La ventaja no estará en las métricas estructurales globales, sino en la **calidad del conjunto de ajuste** y, por tanto, en el **sesgo del efecto estimado**.

Metodología

Pipeline (30 réplicas independientes)

1. **Datos:** red **ALARM** (37 nodos, 46 aristas) como verdad fundamental; 5 000 obs. por réplica (pgmpy).
2. **AG order-based:** permutación $\Rightarrow$ aciclicidad garantizada; score BIC gaussiano; cruce OX, mutación swap, torneo, elitismo.
3. **DML** parcialmente lineal (cross-fitting + bosques aleatorios).
4. **Refutadores:** causa común, placebo, submuestra.

Comparado contra

- Hill-Climbing (mismo score)
- PC (Fisher-z)
- Orden aleatorio (ablación)

Métricas orientadas a identificación

- Cobertura de confusores
- Contaminación por descendientes


Tratamiento $CO \rightarrow BP$ (presión arterial).

Resultados

Recuperación estructural: el AG lidera

Método	F1 esq.	SHD
Algoritmo genético	0,689	42,6
Hill-Climbing (BIC)	0,649	51,2
PC (Fisher-z)	0,675	46,9
Orden aleatorio	0,591	67,0

Media sobre 30 réplicas. La ablación aleatoria (0,591) muestra que la ventaja viene de la **búsqueda evolutiva**, no de la representación.



El hallazgo decisivo: calidad del conjunto de ajuste

Método	Cobertura confusores	Contaminación descendientes	Sesgo vs. oráculo
Algoritmo genético	1,000	0,0 %	0,0020
Hill-Climbing (BIC)	0,700	6,7 %	0,0123
PC (Fisher-z)	0,650	23,3 %	0,0257
Orden aleatorio	0,567	46,7 %	0,0173


Lectura

El AG es el **único** que recupera el 100 % de los confusores y **nunca** contamina el conjunto con descendientes. Su sesgo es **un orden de magnitud menor**. El PC, competitivo en SHD, es el **peor** en sesgo.

Estimación del efecto y robustez



Estimación / prueba	ATE
Sin ajuste (sesgado)	0,325
DAG verdadero (oráculo)	0,319
DAG del AG	0,319
DAG del PC	0,341
Causa común aleatoria	0,315
Tratamiento placebo	-0,001
Submuestra 80 %	0,317

Los tres refutadores aprueban en el **100 %** de las réplicas.



El AG concentra su efecto en el valor del oráculo;
el PC se desplaza por encima.

Estructura recuperada y convergencia



Izq.: DAG verdadero vs. recuperado (verde = acierto, rojo = falso positivo). Der.: el mejor individuo y la media poblacional convergen sin colapso prematuro.

Discusión y conclusiones

¿Por qué basta una estructura imperfecta?

- Para identificar un efecto **no se necesita el DAG completo**, sino un conjunto de ajuste con los confusores relevantes y sin descendientes del tratamiento.
- El error estructural **no es homogéneo**: una arista mal orientada lejos del tratamiento es casi inocua; un confusor omitido, no.
- Por eso el **SHD engaña**: el PC luce competitivo en SHD y es el peor en sesgo. Las métricas orientadas a identificación ordenan los métodos por su **utilidad causal real**.

1. Un AG order-based automatiza el descubrimiento estructural con calidad suficiente para que el DML entregue efectos **insesgados** (0,319 vs. 0,319 del oráculo).
2. **Contribución metodológica:** evaluar el descubrimiento causal con **cobertura de confusores** y **contaminación por descendientes**, no solo con SHD.
3. Se cierra el vacío entre descubrimiento evolutivo y estimación semiparamétrica robusta.

Trabajo futuro: conocimiento de dominio para la orientación; puntajes discretos; levantar suficiencia causal; datos biomédicos reales.

- Repositorio público (MIT): código modular, 35 pruebas, configs YAML, **semillas fijadas**, hardware y versiones registradas.
- Todo el experimento se reproduce con un comando; cuaderno listo para **Google Colab**.
- Coherencia verificada entre **paper**, **proyecto de tesis** y **código**.

`github.com/diego-555-dmg/causal-ga-dml`

Gracias

¿Preguntas?