

UNIVERSIDAD NACIONAL DE INGENIERÍA

**UNIDAD DE POSGRADO FACULTAD DE INGENIERÍA
ECONÓMICA, ESTADÍSTICA Y CIENCIAS SOCIALES
ESCUELA DE POSGRADO**



PLAN DE TESIS
**“ESPECIFICACIÓN AUTOMATIZADA EN DESCUBRIMIENTO
CAUSAL MEDIANTE EL ENFOQUE GENÉTICO”**

PARA OBTENER EL GRADO ACADÉMICO DE
DOCTOR EN CIENCIAS E INGENIERÍA ESTADÍSTICA

ELABORADO POR:

DIEGO ALONSO CÓRDOVA AYALA

ASESOR:

DR. JAIME ENRIQUE LINCOVIL CURIVIL

LIMA, PERÚ

2026

Resumen

La inferencia causal requiere un Grafo Acíclico Dirigido (DAG) especificado correctamente como condición previa para aplicar el Modelado Causal Estructural (SCM) y estimar efectos de intervención. Especificar manualmente dicho grafo requiere un conocimiento del dominio que es necesariamente incompleto, y los algoritmos clásicos de descubrimiento causal sufren una degradación de su desempeño a medida que crece el número de variables. El presente trabajo tiene como objetivo evaluar la eficacia de los algoritmos genéticos para automatizar el descubrimiento estructural y su articulación con el Double Machine Learning (DML) en la estimación de efectos. Se utilizó un diseño experimental de simulación con treinta réplicas independientes, la red bayesiana de referencia se empleó como verdad fundamental, se simuló 5 000 observaciones por réplica y se recuperó la estructura con un algoritmo genético (AG) basado en ordenamientos gobernado por un score gaussiano BIC. El desempeño se comparó con tres métodos de referencia: Hill-Climbing con el mismo score, el algoritmo PC con test Fisher-z y una ablación de orden aleatorio y se evaluó no sólo con métricas estructurales (Distancia de Hamming Estructural, precisión, recall y F1) sino con dos indicadores orientados a la identificación: la cobertura de confusores y la contaminación del conjunto de ajuste por descendientes del tratamiento. Los resultados demuestran que el AG alcanza el mejor F1 de esqueleto ($0,689 \pm 0,020$), que es el único método capaz de recuperar el 100 % de los verdaderos confusores en las treinta réplicas y el único que nunca contamina el conjunto de ajuste, con un sesgo respecto del DAG verdadero un orden de magnitud menor que el de sus competidores (0,0020 frente a 0,0123–0,0257). Por tanto, se concluye que el enfoque genético sí automatiza el descubrimiento estructural con DML, cerrando el vacío de la especificación manual del grafo en conjunto de datos complejos.

Palabras clave: descubrimiento causal, algoritmos genéticos, grafo acíclico dirigido, Double Machine Learning, modelado causal estructural.

Abstract

Contemporary causal inference requires a correctly specified Directed Acyclic Graph (DAG) as a precondition for applying the Structural Causal Model (SCM) framework and estimating intervention effects. Manual graph specification depends on necessarily incomplete domain knowledge, and classical causal discovery algorithms degrade as the number of variables grows. This research evaluates the effectiveness of genetic algorithms for automating structural discovery and their coupling with Double Machine Learning (DML) for effect estimation. Through a simulation-based experimental design with thirty independent replications, the benchmark ALARM Bayesian network (37 nodes, 46 edges) was used as ground truth, 5,000 observations were simulated per replication, and the structure was recovered with an order-based genetic algorithm driven by a Gaussian BIC score. Performance was benchmarked against three reference methods —Hill-Climbing with the same score, the PC algorithm with a Fisher-z test, and a random-order ablation— and assessed not only with structural metrics (Structural Hamming Distance, precision, recall, and F1) but with two identification-oriented indicators: confounder coverage and contamination of the adjustment set by descendants of the treatment. Results show that the genetic algorithm attains the best skeleton F1 (0.689 ± 0.020), is the only method recovering 100 % of the true confounders across all thirty replications, and the only one that never contaminates the adjustment set, with a bias relative to the true DAG an order of magnitude smaller than its competitors (0.0020 versus 0.0123–0.0257). All three statistical refuters passed in every replication. It is concluded that the genetic approach automates the structural discovery that DML requires, closing the manual graph-specification gap in complex databases.

Keywords: causal discovery, genetic algorithms, directed acyclic graph, Double Machine Learning, structural causal model.

Índice de Contenido

Resumen.....	2
Abstract	3
Índice de Contenido	4
Índice de Tablas	6
Índice de Figuras.....	7
Capítulo I. Introducción	8
1.1 Situación Problemática	8
1.2 Objetivos	11
1.2.1 Objetivo General.....	11
1.2.2 Objetivos Específicos.....	11
1.3 Preguntas de Investigación	12
1.4 Hipótesis (paradigma y marco teórico).....	12
1.5 Importancia de la Investigación	13
1.6 Limitaciones.....	13
Capítulo II. Revisión de la Literatura	15
2.1 Del SEM confirmatorio al Modelado Causal Estructural	15
2.2 Identificación, conjuntos de ajuste y equivalencia de Markov	15
2.3 Descubrimiento de estructura: restricciones, score e híbridos.....	16
2.4 Computación evolutiva aplicada al aprendizaje de estructura.....	17
2.5 Optimización continua y aprendizaje diferenciable de DAG	18
2.6 Estimación semiparamétrica robusta del efecto causal.....	18
2.7 Evaluación y comparabilidad en descubrimiento causal	19
2.8 Conclusión (Vacío de conocimiento).....	20
Capítulo III. Metodología	22
3.1 Datos y operacionalización	22
3.2 Descubrimiento estructural mediante algoritmo genético	22
3.3 Métodos de referencia.....	23
3.4 Evaluación estructural y de identificabilidad.....	23
3.5 Estimación del efecto causal	24
3.6 Validación de robustez.....	24
3.7 Diseño Monte Carlo y reproducibilidad	25
3.8 Resultados preliminares	26

3.9 Trabajo futuro previsto	32
Referencias bibliográficas.....	33
Anexos	38

Índice de Tablas

Tabla 1 Comparación de los enfoques de descubrimiento de estructura causal.	20
Tabla 2 Hiperparámetros del algoritmo genético y del estimador.	25
Tabla 3 Recuperación estructural por método (30 réplicas independientes).	27
Tabla 4 Calidad del conjunto de ajuste y consecuencia estimacional.	27
Tabla 5 Estimación del efecto causal y pruebas de robustez.	28

Índice de Figuras

Figura 1 DAG verdadero de la red ALARM (izquierda) frente al DAG recuperado por el algoritmo genético (derecha).	30
Figura 2 Convergencia del algoritmo genético.	31
Figura 3 F1 del esqueleto por método (media $\pm$ desviación estándar).	31
Figura 4 Distribución del efecto estimado por método frente al DAG verdadero.	32

Capítulo I. Introducción

1.1 Situación Problemática

Por décadas se ha utilizado el Modelado de Ecuaciones Estructurales (SEM) con un enfoque mayoritariamente confirmatorio, orientado al análisis de estructuras de covarianza y variables latentes, y aún es productivo en esa tradición (Sandoval-Álvarez, 2025). La inferencia causal moderna, por otra parte, requiere la disciplina del Modelado Causal Estructural (SCM), que plantea supuestos no paramétricos, codifica las intervenciones mediante el operador do y facilita la estimación de contrafactuales (Pearl, 2009; Peters et al., 2017). En este contexto, el requisito indispensable es disponer de un Grafo Acíclico Dirigido (DAG) especificado correctamente, de él depende tanto la identificación del estimando como la validez del criterio de la puerta trasera, cabe señalar que sin estructura no hay identificación, y por tanto, sin identificación ninguna sofisticación estadística posterior produce una estimación interpretable como causal.

Un primer problema en el descubrimiento causal es combinatorio, y su magnitud tiende a ser subestimada. El número de DAG etiquetados sobre p variables crece más que exponencialmente: existen cerca de $4,2 \times 10^{18}$ grafos posibles para 10 variables y para las 37 variables de una red biomédica moderadamente grande el número sobrepasa cualquier esperanza de enumeración exhaustiva (Robinson, 1977). Adicionalmente, la optimización de la estructura con respecto a un score descomponible es NP-difícil (Chickering, 2002), de forma que cualquier procedimiento práctico es necesariamente heurístico. La literatura especializada del campo evidencia que ningún algoritmo es consistentemente superior, y que el desempeño empeora a medida que crece el número de variables, el ruido de medición y el tamaño de la muestra (Kitson et al., 2023; Scanagatta et al., 2019; Vowels et al., 2022). La validación empírica a gran escala de Constantinou et al. (2021) mostró que la exactitud estructural de los

algoritmos establecidos se reduce drásticamente cuando existen datos ruidosos, una condición que es la regla y no la excepción en los registros clínicos y administrativos reales.

El segundo problema es que la solución típica, especificar el DAG a mano, es más frágil y propensa a errores de lo que normalmente se piensa. En general, el grafo que el investigador dibuja depende de un conocimiento de dominio incompleto y lleno de sesgos teóricos, los errores no se distribuyen de forma adecuada, incluir en el conjunto de ajuste un colisionador o un mediador creyéndolo un confusor no atenúa la estimación, introduce sesgo donde no lo había.

Esa asimetría hace de cada arista mal orientada un preciso riesgo estimacional. A esto hay que sumar una fuente de arbitrariedad rara vez señalada: Kitson y Constantinou (2024) demostraron que muchos algoritmos ampliamente empleados, particularmente las variantes de hill-climbing, son más sensibles al orden en que se leen las variables del conjunto de datos que a las variaciones en el tamaño de la muestra o en los hiperparámetros. Dado que este orden es arbitrario, una parte importante de los resultados publicados y de los rankings de desempeño pierden validez. Los resultados del estudio de Constantinou et al. (2023) con datos de COVID-19 en el Reino Unido, son un ejemplo de lo que se puede encontrar cuando el descubrimiento estructural se aplica a un dominio real con alto impacto.

Al mismo tiempo, el aprendizaje automático ha ayudado a grandes avances en la estimación de efectos causales. Double Machine Learning proporciona un estimador semiparamétrico de convergencia raíz- n que, a través de la ortogonalización de Neyman y la validación cruzada, ofrece efectos insesgados incluso con funciones de estorbo de alta dimensión (Chernozhukov et al., 2018); los bosques causales amplían esta lógica a la heterogeneidad del efecto (Wager & Athey, 2018), y los metalearners extienden el principio a cualquier aprendizaje supervisado (Künzel et al., 2019). No obstante todos estos estimadores comparten una importante limitación estructural: son incapaces de percibir el grafo. Sus

garantías son condicionales a recibir un conjunto de ajuste válido, pero ninguno tiene ningún mecanismo para comprobar esa validez. De esta forma los avances en estimación han desplazado el cuello de botella a la especificación estructural, en lugar de eliminarlo.

De la confluencia de ambos frentes surge el vacío de conocimiento que motiva esta investigación, y conviene enunciarlo con precisión porque no es un vacío de métodos sino de articulación y de evaluación. Las métricas de evaluación de los algoritmos de descubrimiento causal se basan casi exclusivamente en métricas estructurales globales, Distancia de Hamming Estructural, precisión, recall y F1, que tratan por igual a todas las aristas del grafo, mientras que la identificación de un efecto concreto depende únicamente de una región muy localizada: la vecindad del tratamiento. Cabe señalar que, un algoritmo puede conseguir mejorar el SHD global pero empeorar a la vez el conjunto de ajuste. En segundo lugar, este tipo de literatura rara vez cuantifica la consecuencia estimacional de sus errores estructurales: no informa cuánto sesgo introduce en el efecto finalmente estimado un determinado SHD.

En tercer lugar, los trabajos evolutivos recientes, con incorporación de conocimiento de dominio y operadores dinámicos (Mao et al., 2025), hiperheurísticas con restricciones flexibles y estrictas (Dang et al., 2025), o mejoras de los operadores genéticos clásicos (Sun & Zhou, 2022), se comparan entre sí a nivel estructural, pero no dentro del ciclo completo de identificación y estimación. En cuarto lugar, los estudios de simulación tienden a presentar sólo una corrida, sin cuantificar la variabilidad entre réplicas, lo que impide distinguir si una mejora es metodológica o el resultado de una buena suerte en el muestreo; a esto se suma la advertencia de Reisach et al. (2021) sobre la facilidad para obtener buenos resultados en benchmarks simulados debido a artefactos de la generación de los datos.

A modo de síntesis, el problema no es que falten algoritmos de descubrimiento o estimadores robustos, sino que no hay evidencia de si un procedimiento automatizado de descubrimiento estructural recupera fielmente la parte del grafo que realmente se necesita para la identificación,

evaluado en la métrica que importa, el sesgo del efecto estimado, y con la variabilidad debidamente cuantificada.

1.2 Objetivos

1.2.1 Objetivo General

Comprobar que los algoritmos genéticos sean eficaces para automatizar el descubrimiento causal bajo los postulados de Modelado Causal Estructural (SCM) y que la estructura recuperada sustente estimaciones causales insesgadas a través de Double Machine Learning.

1.2.2 Objetivos Específicos

- Implementar un enfoque de optimización evolutiva que busque en el espacio de posibles Grafos Acíclicos Dirigidos (DAG), asegurando por construcción que la estructura resultante soporte la lógica de intervenciones propia del SCM.
- Validar empíricamente la topología de la red causal descubierta por el algoritmo genético respecto a la estructura original de una red de referencia, mediante precisión, recall, F1 y Distancia de Hamming Estructural, y frente a métodos representativos de los métodos basados en score y en restricciones.
- Evaluar la calidad del conjunto de ajuste derivado de la estructura descubierta en términos de cobertura de confusores y de contaminación por descendientes del tratamiento, indicadores directamente ligados a la identificabilidad del efecto.
- Estimar el efecto causal con ese conjunto de ajuste usando Double Machine Learning, cuantificar su sesgo respecto al efecto obtenido con el DAG verdadero y evaluar su robustez con refutadores estadísticos, reportando la variabilidad sobre réplicas independientes.

1.3 Preguntas de Investigación

1.2.1 Pregunta General

¿De qué manera el uso de algoritmos genéticos mejora la especificación automática y el descubrimiento de Grafos Acíclicos Dirigidos (DAG) en el contexto del Modelado Causal Estructural (SCM) para bases de datos complejas?

1.2.1 Preguntas específicas

- ¿En qué medida recupera el algoritmo genético la estructura verdadera de una red de referencia y cómo se compara con métodos representativos de las familias basadas en score y en restricciones?
- ¿El conjunto de ajuste derivado de la estructura descubierta contiene los confusores relevantes y excluye a los descendientes de la variable de tratamiento?
- ¿Qué magnitud de sesgo introduce el error estructural residual en el efecto causal finalmente estimado?
- ¿Qué tan estable es esa estimación frente a pruebas de sensibilidad y a la variabilidad del muestreo?

1.4 Hipótesis

Bajo el paradigma positivista y la perspectiva cuantitativa basada en experimentos y simulaciones se plantea la siguiente hipótesis de trabajo: la especificación automatizada a través de algoritmos genéticos recupera una estructura causal de suficiente calidad como para que un estimador robusto como el Double Machine Learning genere un efecto causal estadísticamente indistinguible del obtenido con el DAG verdadero. En consonancia con el vacío de conocimiento detectado, se plantea como hipótesis auxiliar que la ventaja del enfoque evolutivo no se plasmará principalmente en las métricas estructurales globales, donde la equivalencia de Markov impone un techo teórico, sino en la calidad del conjunto de ajuste y,

por tanto, en el sesgo del efecto estimado. Tres pilares constituyen el marco teórico que articula ambas hipótesis: el Modelado Causal Estructural de Pearl (2009), la teoría del aprendizaje de estructuras de redes bayesianas (Kitson et al., 2023; Spirtes et al., 2000) y la teoría de la estimación semiparamétrica con ortogonalización de Neyman (Chernozhukov et al., 2018).

1.5 Importancia de la Investigación

El valor metodológico del estudio radica en la unión entre el descubrimiento causal evolutivo y la estimación semiparamétrica robusta, dos comunidades que han evolucionado en paralelo con muy poco contacto entre ellas. Su importancia teórica es que para poder identificar un efecto particular no es necesario recuperar el DAG completo, sino tan solo un conjunto de ajuste que incluya los confusores adecuados y excluya a los descendientes del tratamiento, lo cual reduce de forma considerable la demanda sobre el descubrimiento estructural y modifica la forma en que se evalúan los criterios.

Desde un punto de vista metodológico, el estudio propone dos indicadores –cobertura de confusores y contaminación por descendientes–, que traducen el error estructural al lenguaje de la identificabilidad y permiten comparar algoritmos por su utilidad para la inferencia causal y no solo por su fidelidad topológica. En la práctica, el procedimiento permite realizar análisis causales fiables en biomedicina o políticas públicas cuando asumir que se tiene un DAG perfecto es poco realista, lo que ayuda a tomar decisiones basadas en evidencias causales y no solo correlacionales. Finalmente, la publicación del código como repositorio abierto con semillas fijadas, hiperparámetros documentados y hardware especificado, es una respuesta a la creciente demanda de reproducibilidad computacional en la investigación estadística.

1.6 Limitaciones

En primer lugar, se establece la limitación teórica referida a la orientación de bordes dentro de una clase de equivalencia de Markov no es identificable a partir de datos puramente observacionales, de forma que ningún método basado únicamente en observación puede

recuperar el DAG dirigido completo; esto explica la brecha sistemática entre las métricas de esqueleto y las dirigidas.

La segunda limitación es de modelado estadístico, las variables categóricas de la red se codifican ordinalmente y se evalúan con un puntaje gaussiano. Es una aproximación estándar y escalable, también empleada en aplicaciones biomédicas de alta dimensión (Graafland & Gutiérrez, 2022), pero puntajes específicos para datos discretos podrían mejorar la orientación (Yaman & Cengiz, 2025).

La tercera limitación es la validez externa, aunque la validación se realiza sobre una red de referencia con estructura conocida, que es una condición necesaria para medir objetivamente la recuperación, los hallazgos sobre datos simulados no se transfieren automáticamente a datos reales, donde la verdad fundamental es incierta y donde pueden operar artefactos de la propia simulación (Reisach et al., 2021). Se plantea como siguiente paso del proyecto de tesis la extensión a bases de datos reales de biomedicina.

La cuarta tiene que ver con el alcance: el estudio asume suficiencia causal, es decir, ausencia de confusores latentes. Trabajar con grafos ancestrales máximos y algoritmos de la familia FCI, exigiría levantar ese supuesto, extensión prevista para etapas posteriores.

Capítulo II. Revisión de la Literatura

2.1 Del SEM confirmatorio al Modelado Causal Estructural

El Modelado de Ecuaciones Estructurales originalmente era un instrumento confirmatorio de estructuras de covarianza y de variables latentes, y aún sigue siendo un instrumento activo en el análisis de efectos indirectos condicionales en la administración y las ciencias sociales (Sandoval-Álvarez, 2025). Su lógica, sin embargo, asume que el modelo estructural está ya especificado y sólo evalúa el ajuste del modelo a los datos.

Fue la revolución causal impulsada por Pearl (2009) la que dio un vuelco al problema. El SCM da una semántica formal a las intervenciones mediante el operador *do*, a los contrafactuales, y define la jerarquía de tres niveles, asociación, intervención y contrafactual, mediante la cual se organiza cualquier pregunta causal. Peters y col. (2017) codificaron los fundamentos y los algoritmos del marco, afianzando la distinción entre lo que se puede aprender de datos observacionales y lo que necesita supuestos adicionales o intervención experimental. El cambio conceptual es grande: el grafo ya no es un dispositivo de representación, sino que se convierte en el objeto del cual depende la identificabilidad. Con ese avance a cambio, la especificación estructural pasa a llevar el peso de la prueba. Autores como Trinchera y Col (2026) enfrentan de frente esta tensión en la tradición del modelado basado en compuestos, automatizando la búsqueda de especificaciones a través de un enfoque genético; su trabajo confirma que la especificación manual es un cuello de botella reconocido incluso dentro de la comunidad SEM.

2.2 Identificación, conjuntos de ajuste y equivalencia de Markov

El criterio de la puerta trasera permite identificar, a partir de datos observacionales, si un tratamiento tiene un efecto sobre un resultado: un conjunto de variables cumple dicho criterio cuando bloquea todos los caminos no causales entre el tratamiento y el resultado y no incluye descendientes del tratamiento (Pearl, 2009). Un resultado clásico, fundamental para esta investigación, es que el conjunto de padres del tratamiento en el DAG causal siempre cumple

ese criterio. La consecuencia operativa es directa: descubrir la estructura equivale a descubrir un conjunto de ajuste válido, y la calidad del descubrimiento puede ser evaluada en términos de identificabilidad y no sólo de fidelidad topológica.

La equivalencia de Markov es el límite de lo que puede conseguirse. Los DAG que codifiquen las mismas independencias condicionales son indistinguibles con datos observacionales, por lo tanto la orientación de algunas aristas es en principio irrecuperable (Spirtes et al., 2000). Chickering (2002) planteó las implicaciones para la búsqueda basada en puntaje y demostró la NP-dificultad del problema de encontrar la estructura óptima. La razón por la cual cualquier evaluación honesta debe reportar por separado las métricas de esqueleto y las dirigidas, es esa doble frontera, teórica y computacional: penalizar a un algoritmo por no orientar lo que no puede orientarse equivale a confundir un límite del problema con un defecto del método.

2.3 Descubrimiento de estructura: restricciones, score e híbridos

Los métodos basados en restricciones, cuyo ejemplo canónico es el algoritmo PC, construyen el esqueleto eliminando adyacencias mediante pruebas de independencia condicional, y posteriormente orientan v-estructuras y aplican reglas de propagación (Spirtes et al., 2000), su comportamiento depende críticamente de la potencia de las pruebas y acumula errores en cascada: una prueba errónea temprana se propaga a todas las decisiones posteriores. También Colombo y Maathuis (2014) demostraron que la versión original es sensible al orden de las variables y propusieron variantes que no dependen del orden.

Los métodos de score plantean el problema como una optimización sobre el espacio de DAGs de una función penalizada de bondad de ajuste. La búsqueda exacta con programación lineal entera es factible en dominios pequeños (Bartlett & Cussens, 2017) y variantes de A* con conjuntos óptimos potenciales de padres han ampliado ese ámbito (He et al., 2023), pero en dominios con decenas de variables la búsqueda heurística sigue siendo la única alternativa práctica. El algoritmo de referencia en este grupo es el hill-climbing voraz, donde el clásico

K2 ha sido mejorado por Behjati y Beigy (2020). Las estrategias híbridas intentan combinar ambas lógicas, en primer lugar restringen el espacio de padres potenciales con las pruebas de independencia y en segundo lugar optimizan el score dentro del espacio restringido (Tsamardinos et al. 2006). Estos algoritmos fueron puestos al alcance de la comunidad aplicada a través de herramientas ya consolidadas como bnlearn (Scutari, 2010). Los estudios comparativos coinciden en que ningún método domina de forma uniforme, y que el desempeño relativo depende del tamaño muestral, del ruido y de la densidad del grafo (Constantinou et al., 2021; Scutari et al., 2019). Lo que tienen en común todos ellos es que exploran localmente el espacio de estructuras y, por lo tanto, están expuestos a quedar atrapados en óptimos locales.

2.4 Computación evolutiva aplicada al aprendizaje de estructura

Dado el carácter combinatorio del problema, los algoritmos genéticos permiten una búsqueda global poblacional que evita quedar atrapada en óptimos locales. El trabajo seminal de Larrañaga et al. (1996b) estudió el efecto de los parámetros de control en el aprendizaje de estructuras usando algoritmos genéticos; ese mismo año, Larrañaga et al. (1996a) plantearon la representación que se usa en este estudio: en lugar de buscar el grafo directamente, se busca el mejor ordenamiento de las variables.

La elección de la representación no es un detalle de implementación, sino la decisión de diseño más importante. Al codificar el grafo como una matriz de adyacencia, se hace necesario arreglar o desechar a los individuos cíclicos que producen el cruce y la mutación, consumiendo la mayor parte del presupuesto computacional. Codificarlo como permutación de nodos reduce el espacio de búsqueda de grafos dirigidos posibles a los ordenamientos y garantiza la aciclicidad por construcción. La conclusión de Kitson y Constantinou (2024) respecto a la sensibilidad de los algoritmos al orden de las variables, refuerza esta decisión desde un ángulo inesperado: si el orden de lectura de los datos tiene un efecto decisivo sobre la exactitud de los algoritmos convencionales, optimizarlo explícitamente, en vez de aceptarlo como un dato arbitrario, es

una respuesta metodológicamente coherente al problema. La línea evolutiva se ha renovado con vigor, autores como Sun y Zhou (2022) mejoraron los operadores genéticos tradicionales para el aprendizaje de redes bayesianas; Mao et al. (2025) añaden conocimiento de dominio y operadores dinámicos de mutación para acelerar la convergencia en descubrimiento causal; y Dang et al. (2025) incorporan restricciones flexibles y estrictas mediante una hiperheurística basada en bandidos multibrazo. Los trabajos comparten una característica que resulta relevante para nuestro estudio: los autores evalúan sus propuestas únicamente con métricas estructurales, sin comprobar si la estructura recuperada sirve al objetivo último de estimar un efecto.

2.5 Optimización continua y aprendizaje diferenciable de DAG

Una línea de trabajo paralela reformulaba el problema combinatorio en términos de optimización continua. La caracterización diferenciable de la aciclicidad introducida por Zheng et al. (2018) reemplazó la restricción discreta por una igualdad suave, lo que abrió la puerta al uso de optimizadores basados en gradientes y a la integración con arquitecturas de aprendizaje profundo. A este respecto, el trabajo de revisión de Vowels et al. (2022) documenta la rápida expansión de variantes sobre esta idea. La evidencia posterior, sin embargo, invita a la cautela, autores como Reisach y col. (2021) mostraron que gran parte del desempeño reportado por estos métodos en benchmarks simulados puede deberse a artefactos de generación de datos, específicamente a la relación entre la varianza marginal de las variables y su posición topológica, y no a una genuina capacidad de descubrimiento. La lección metodológica es doble, por un lado, es conveniente evaluar sobre redes de referencia con parámetros publicados en vez de datos generados ad hoc, y es conveniente complementar las métricas estructurales con indicadores que no pueden ser satisfechos por artefactos de escala.

2.6 Estimación semiparamétrica robusta del efecto causal

Double Machine Learning proporcionó un estimador semiparamétrico de convergencia raíz- n que combina la ortogonalización de Neyman, anulando el sesgo de regularización de primer

orden, con la validación cruzada por particiones, eliminando el sesgo de sobreajuste, lo cual permite emplear aprendices no paramétricos para las funciones de estorbo sin comprometer la inferencia (Chernozhukov et al., 2018). Los bosques causales extendieron la lógica a la estimación de efectos heterogéneos con garantías de normalidad asintótica (Wager & Athey, 2018), y los metalearners generalizaron el principio a cualquier algoritmo supervisado base (Künzel et al., 2019). El ciclo entero de modelado, identificación, estimación y refutación fue implementado de forma práctica por la biblioteca DoWhy (Sharma & Kiciman, 2020).

Pero todos estos estimadores tienen en común una característica que define el problema de esta investigación: son estructuralmente ciegos. Sus garantías de insesgadez dependen de que se les provea un conjunto de ajuste válido, y ninguno posee un mecanismo interno para verificar esa validez. Si los alimentamos con un colisionador, o un descendiente de tratamiento, obtenemos estimaciones sesgadas con intervalos de confianza estrechos, es decir error equivocado con confianza. La potencia del estimador no sólo compensa el error estructural, sino que lo oculta.

2.7 Evaluación y comparabilidad en descubrimiento causal

Con respecto a las prácticas de evaluación, mayoritariamente se emplea la Distancia de Hamming Estructural y las métricas de precisión, exhaustividad y F1 sobre las aristas, que se calculan respecto a una red de referencia. Kitson et al. (2023) y Scanagatta et al. (2019) demuestran que la heterogeneidad de protocolos imposibilita la comparabilidad entre estudios, mientras que Yaman y Cengiz (2025) muestran cómo incluso la elección del criterio de score altera significativamente la estructura recuperada, lo cual pone de relieve la necesidad de comparar métodos bajo un score idéntico si se quiere aislar el efecto de la estrategia de búsqueda. El problema de fondo de estas métricas es que asignan un peso constante a todas las aristas del grafo, pero la identificación de un efecto concreto depende de una región muy localizada: la vecindad del tratamiento. Dos estructuras con idéntico SHD pueden ser completamente diferentes en su utilidad causal dependiendo de dónde se concentren sus

errores. En la Tabla 1 se resumen las familias de métodos revisadas y sus correspondientes compromisos característicos.

Tabla 1
Comparación de los enfoques de descubrimiento de estructura causal.

Familia	Mecanismo	Fortaleza	Limitación principal
Basada en restricciones (PC)	Pruebas de independencia condicional	Fundamento teórico explícito; escalable en grafos ralos	Errores en cascada; sensibilidad al orden y a la potencia de las pruebas
Basada en score (Hill-Climbing, A*)	Optimización de un score penalizado	Criterio global y comparable	Óptimos locales; NP-dificultad de la búsqueda exacta
Híbrida (MMHC)	Restricción del espacio + score	Compromiso favorable entre exactitud y costo	Hereda las debilidades de ambas familias
Continua (NOTEARS)	Aciclicidad diferenciable	Optimización por gradiente; integración con aprendizaje profundo	Vulnerable a artefactos de los datos simulados
Evolutiva (AG)	Búsqueda poblacional global	Escapa de óptimos locales; aciclicidad garantizada por representación	Mayor costo computacional; evaluada solo en el plano estructural

Nota. Elaboración propia a partir de Bartlett y Cussens (2017), Chickering (2002), Dang et al. (2025), Kitson et al. (2023), Larrañaga et al. (1996a), Spirtes et al. (2000), Tsamardinos et al. (2006) y Zheng et al. (2018).

2.8 Conclusión (Vacío de conocimiento)

La revisión de literatura muestra dos comunidades que han evolucionado en paralelo con muy poco contacto: la del descubrimiento estructural, en sus variantes basadas en restricciones, en score, híbridas, continuas y evolutivas, y la de la estimación causal semiparamétrica robusta. El primero perfecciona algoritmos que recuperan grafos y los evalúan con métricas topológicas, el segundo perfecciona estimadores que asumen el grafo como dado.

Ese vacío está constituido por cuatro componentes precisos. En primer lugar, no está claro si la estructura que un algoritmo genético descubre por sí solo basta para que un estimador como el Double Machine Learning entregue efectos libres de sesgos. En segundo lugar, carece de un criterio de evaluación que interprete el error estructural en términos de identificabilidad, separando los errores inofensivos, aristas muy alejadas del tratamiento, de los que son perjudiciales, confusores omitidos o descendientes incorporados. En tercer lugar, las comparaciones disponibles entre métodos de descubrimiento no se llevan a cabo dentro del ciclo completo de identificación y estimación, de tal forma que no se sabe cuál es la consecuencia estimacional de las diferencias estructurales reportadas. En cuarto lugar, la mayoría de los estudios analizados solo han realizado una ejecución, lo cual impide separar la mejoría en la metodología de la variabilidad muestral.

Esta investigación cubre dicho vacío en sus cuatro componentes: propone y valida empíricamente la sinergia entre descubrimiento evolutivo y estimación semiparamétrica, introduce la cobertura de confusores y la contaminación por descendientes como métricas orientadas a la identificación, compara el algoritmo genético contra métodos representativos de las familias basadas en score y en restricciones, además de una ablación que aísla la contribución de la maquinaria evolutiva, y reporta todos los resultados como media y desviación estándar sobre treinta réplicas independientes.

Capítulo III. Metodología

3.1 Datos y operacionalización

Se emplea la red bayesiana de referencia ALARM (A Logical Alarm Reduction Mechanism), la cual está conformada por 37 variables categóricas y 46 aristas dirigidas que codifican relaciones diagnósticas y hemodinámicas del monitoreo médico intraoperatorio (Beinlich et al., 1989). Se trata de un estándar bien establecido en la literatura del aprendizaje de estructuras, lo que permite que se puedan comparar los resultados obtenidos con trabajos anteriores y evita los artefactos que pueden aparecer cuando se utilizan datos generados ad hoc (Reisach et al., 2021).

Para cada réplica se generan 5 000 observaciones mediante muestreo directo de la distribución de probabilidad conjunta con la biblioteca pgmpy. Las categorías se codifican ordinalmente con números enteros, una práctica habitual que permite la aplicación de puntajes gaussianos escalables en el aprendizaje de la estructura de los datos ordinales (Graafland & Gutiérrez, 2022). El gasto cardíaco (CO) se opera como tratamiento y la presión arterial (BP) como resultado, un par entre los que existen confusores estructurales identificables en el grafo verdadero: la frecuencia cardíaca (HR) y el volumen sistólico (STROKEVOLUME).

3.2 Descubrimiento estructural mediante algoritmo genético

Se emplea un algoritmo genético basado en ordenamientos en la línea de Larrañaga et al. (1996a). Cada individuo es una permutación de los 37 nodos que representa un orden topológico, dado este orden, se selecciona por avidez el mejor conjunto de padres de cada nodo entre sus predecesores. Por construcción, la aciclicidad está garantizada, lo que elimina el costo de reparar grafos inválidos y reduce el espacio de búsqueda de los grafos dirigidos posibles a los ordenamientos de los nodos.

La aptitud de cada individuo es la suma de los puntajes locales bajo un score gaussiano BIC descomponible, calculado a partir de la matriz de covarianza mediante la varianza parcial

conseguida por el complemento de Schur. Esta formulación evita recorrer los datos en cada evaluación: tras precomputar la covarianza una sola vez, el costo de evaluar un nodo depende únicamente del número de padres, lo que permitió realizar 26 516 evaluaciones de score en nueve segundos en la corrida de referencia. El operador de cruce utilizado es el Order Crossover, que preserva la validez de las permutaciones, la mutación es por intercambio de posiciones y la selección se hace por torneo con elitismo.

3.3 Métodos de referencia

Para aislar la contribución de la búsqueda evolutiva se contrasta el algoritmo genético con tres competidores, evaluados exactamente sobre los mismos datos. El primero es un Hill-Climbing con operadores de adición, borrado e inversión que optimiza el mismo score gaussiano BIC, por lo que cualquier diferencia de desempeño se debe atribuir a la estrategia de búsqueda y no a la función objetivo. El segundo es el algoritmo PC con test de independencia condicional Fisher-z, que representa a la familia basada en restricciones (Spirtes et al., 2000). Por último, la tercera es una separación o ablación intencional, es decir, un decodificador de ordenación aleatoria con la misma selección de padres avara que comparte con el algoritmo genético la representación y el decodificador pero no tiene selección, cruce ni mutación.

3.4 Evaluación estructural y de identificabilidad

La estructura recuperada se compara con la original usando la Distancia de Hamming Estructural, que cuenta los bordes faltantes, extra y invertidos, y por precisión, recall y F1 calculados tanto sobre los bordes dirigidos como sobre el esqueleto no dirigido. Es necesaria esa distinción porque la equivalencia de Markov impone un límite teórico a la recuperación de orientaciones. A estas métricas o indicadores comunes, se añaden dos indicadores orientados a la identificación, los cuales constituyen un aporte metodológico del estudio. La cobertura de los confusores mide la proporción de verdaderos padres del tratamiento que se encuentran en el conjunto de ajuste estimado; cualquier valor menor a uno implica confusión residual. Los

descendientes contaminantes indican si el conjunto estimado contiene a alguno de los descendientes del tratamiento, lo que induce un sesgo de colisionador o de sobreajuste. Ambos indicadores convierten el error estructural en un lenguaje identificable y hacen posible comparar los métodos por su utilidad causal efectiva.

3.5 Estimación del efecto causal

Después de recuperar el diagrama dirigido acíclico, el conjunto de ajuste se extrae como los padres del tratamiento, un conjunto que siempre cumple con el criterio de puerta trasera (Pearl, 2009), y se estima el Efecto Promedio del Tratamiento con un Double Machine Learning parcialmente lineal con validación cruzada de dos particiones (Chernozhukov et al., 2018). Para aproximar las funciones de “estorbo” se emplean bosques aleatorios y el parámetro causal se calcula como la razón entre la covarianza de los residuos y la varianza del residuo del tratamiento. En tanto que, para obtener el error estándar se emplea la varianza sándwich de la función de momentos de Neyman. También, se considera el efecto ajustado por el conjunto DAG original u oráculo, y el efecto no ajustado, se introduce una garantía metodológica, la variable de resultado queda fuera explícitamente del conjunto de ajuste, se debe mencionar que, un método de descubrimiento que oriente mal la arista entre tratamiento y resultado pondría a este último entre los padres del primero, y condicionar sobre el propio resultado anula la varianza residual y hace que la estimación se haga degenerada.

3.6 Validación de robustez

Referente a la validación de robustez, se utilizan tres refutadores en el marco del DoWhy (Sharma & Kiciman, 2020), cada uno con un criterio de aprobación explícito. El refutador de causa común aleatoria añade un confusor irrelevante y comprueba que el efecto no varía en más de un 15 % en términos relativos, asimismo, el refutador de tratamiento placebo reemplaza el tratamiento por una permutación aleatoria y requiere que el efecto se colapse a cero. El refutador de submuestra itera la estimación con el 80 % de los datos y comprueba la estabilidad,

en ese sentido, un refutador no confirma la hipótesis causal, sino somete a prueba la hipótesis causal, la cual debería fallar si el efecto fuese un artefacto o ventaja aparente del procedimiento.

3.7 Diseño Monte Carlo y reproducibilidad

El procedimiento completo se efectúa en unas treinta réplicas independientes, cuyas semillas proceden de una semilla maestra mediante una secuencia generadora que asegura flujos estadísticamente independientes. Los resultados se dan como media y desviación estándar sobre réplicas, de forma que ninguna conclusión depende de una realización particular del muestreo o del proceso evolutivo.

La reproducibilidad se trata en cuatro niveles. En cuanto a las semillas, una única semilla madre gobierna la simulación de datos, la inicialización y los operadores del algoritmo genético, las particiones del cross-fitting, los bosques aleatorios y los refutadores. Para el determinismo, el algoritmo genético utiliza una instancia local del generador pseudoaleatorio en lugar del estado global del módulo, y los bosques se ejecutan en un solo hilo, lo que elimina el no determinismo de la programación paralela y también resultó más rápido en este problema. Los hiperparámetros se declaran todos en archivos de configuración externos y se serializan con los resultados, sin constantes ocultas en el código. En lo que respecta al entorno, cada archivo de resultados incluye un registro automático del hardware, el sistema operativo y las versiones de librerías, los cuales se detallan en la Tabla 6. El código completo, junto con pruebas automatizadas que verifican estas propiedades, se entrega como repositorio público.

Tabla 2

Hiperparámetros del algoritmo genético y del estimador.

Componente	Parámetro	Valor
------------	-----------	-------

Datos	Red bayesiana de referencia	ALARM (37 nodos, 46 aristas)
Datos	Observaciones por réplica	5 000
Datos	Tratamiento / resultado	CO / BP
Score	Factor de penalización BIC	3,5
Score	Regularización de la covarianza	1×10^{-6}
Algoritmo genético	Tamaño de población	40
Algoritmo genético	Número de generaciones	60
Algoritmo genético	Grado de entrada máximo	4
Algoritmo genético	Probabilidad de cruce (OX)	0,90
Algoritmo genético	Probabilidad de mutación (swap)	0,30
Algoritmo genético	Tamaño de torneo / elitismo	3 / 2
Double ML	Particiones del cross-fitting	2
Double ML	Árboles / profundidad máxima	100 / 6
PC	Nivel de significación α / condicionante máximo	0,01 / 3
Hill-Climbing	Iteraciones máximas	200
Diseño	Réplicas independientes / semilla maestra	30 / 42

Nota. Los hiperparámetros se declaran en archivos de configuración externos (configs/*.yaml) y se serializan junto con cada archivo de resultados.

3.8 Resultados preliminares

La Tabla 3 evidencia la recuperación estructural por método sobre las treinta réplicas. El algoritmo genético alcanza el mejor F1 de esqueleto ($0,689 \pm 0,020$) y el menor SHD ($42,6 \pm 4,0$), superando al Hill-Climbing que optimiza el mismo score ($0,649 \pm 0,027$) y al PC ($0,675 \pm 0,021$). La ablación de orden aleatorio queda claramente rezagada ($0,591 \pm 0,029$), lo que confirma que la ventaja no proviene de la representación por permutaciones sino de la búsqueda evolutiva que opera sobre ella. La brecha sistemática entre el F1 de esqueleto y el dirigido ($0,689$ frente a $0,535$) es consistente con el límite impuesto por la equivalencia de Markov.

Tabla 3*Recuperación estructural por método (30 réplicas independientes).*

Método	F1 esqueleto	Recall esqueleto	F1 dirigido	SHD
Algoritmo genético	0,689 ± 0,020	0,822 ± 0,021	0,535 ± 0,048	42,6 ± 4,0
Hill-Climbing (BIC)	0,649 ± 0,027	0,798 ± 0,026	0,449 ± 0,074	51,2 ± 6,9
PC (Fisher-z)	0,675 ± 0,021	0,806 ± 0,021	0,472 ± 0,026	46,9 ± 2,9
Orden aleatorio (ablación)	0,591 ± 0,029	0,785 ± 0,035	0,314 ± 0,056	67,0 ± 5,7

Nota. Media ± desviación estándar sobre 30 réplicas. SHD = Distancia de Hamming Estructural; valores menores indican mejor recuperación. Red ALARM, 5 000 observaciones por réplica, semilla maestra 42.

El hallazgo decisivo aparece, sin embargo, en la Tabla 4. El algoritmo genético es el único método que recupera el 100 % de los confusores verdaderos en la totalidad de las réplicas y el único que nunca incorpora descendientes del tratamiento en el conjunto de ajuste. El Hill-Climbing recupera en promedio el 70 % de los confusores y contamina el conjunto en el 6,7 % de las réplicas; el PC recupera el 65 % y contamina en el 23,3 %; la ablación aleatoria contamina en casi la mitad de los casos. La consecuencia estimacional es inmediata: el sesgo absoluto del algoritmo genético respecto del oráculo es de 0,0020, entre seis y trece veces menor que el de sus competidores.

Tabla 4*Calidad del conjunto de ajuste y consecuencia estimacional.*

Método	Cobertura de confusores	Contaminación por descendientes	 Sesgo vs. oráculo
Algoritmo genético	1,000	0,0 %	0,0020
Hill-Climbing (BIC)	0,700	6,7 %	0,0123
PC (Fisher-z)	0,650	23,3 %	0,0257
Orden aleatorio (ablación)	0,567	46,7 %	0,0173

Nota. La cobertura de confusores es la proporción de padres verdaderos del tratamiento presentes en el conjunto de ajuste estimado. La contaminación por descendientes es el porcentaje de réplicas en que el conjunto estimado incluye algún descendiente del tratamiento. El sesgo se calcula respecto del efecto estimado con el conjunto de ajuste del DAG verdadero.

La Tabla 5 sintetiza la estimación del efecto y las pruebas de robustez. El efecto estimado con el conjunto de ajuste del algoritmo genético ($0,319 \pm 0,023$) coincide con el del DAG verdadero ($0,319 \pm 0,023$), mientras que el PC lo sobreestima ($0,341 \pm 0,028$) al omitir un confusor. Los tres refutadores aprobaron en el 100 % de las réplicas: la introducción de una causa común aleatoria no modificó el efecto, el tratamiento placebo colapsó a cero y la reestimación con el 80 % de la muestra se mantuvo estable.

Tabla 5

Estimación del efecto causal y pruebas de robustez

Estimación o prueba	Valor	Interpretación
Sin ajuste alguno	$0,325 \pm 0,013$	Referencia sesgada
Ajuste con el DAG verdadero (oráculo)	$0,319 \pm 0,023$	Referencia insesgada
Ajuste con el DAG del algoritmo genético	$0,319 \pm 0,023$	Coincide con el oráculo
Ajuste con el DAG del Hill-Climbing	$0,310 \pm 0,030$	Sesgo moderado
Ajuste con el DAG del PC	$0,341 \pm 0,028$	Sobreestimación por confusor omitido
Refutador: causa común aleatoria	$0,315 \pm 0,023$	Estable (aprueba en el 100 %)
Refutador: tratamiento placebo	$-0,001 \pm 0,012$	Colapsa a cero (aprueba en el 100 %)
Refutador: submuestra al 80 %	$0,317 \pm 0,032$	Estable (aprueba en el 100 %)


Nota. Media $\pm$ desviación estándar sobre 30 réplicas. Los refutadores se aplican sobre el conjunto de ajuste derivado del algoritmo genético.

Como se observa las figuras 1 a 4 presentan gráficamente estos hallazgos, la comparación estructural entre el DAG original o verdadero y el recuperado, asimismo la convergencia del

proceso evolutivo, luego el desempeño estructural comparado y por último, la distribución del efecto estimado por método frente al valor del oráculo.

Figura 1


DAG original de la red ALARM (izquierda) frente al DAG recuperado por el algoritmo genético (derecha).



Nota. En el grafo recuperado, las aristas en verde coinciden con adyacencias verdaderas y las rojas son falsos positivos. El tratamiento (CO) y el resultado (BP) aparecen destacados. Corrida de referencia con semilla 42.

Figura 2


Convergencia del algoritmo genético.



Nota. Evolución del score BIC del mejor individuo y de la media poblacional a lo largo de 60 generaciones. La separación sostenida entre ambas curvas indica que la población conserva diversidad y no colapsa prematuramente.

Figura 3


F1 del esqueleto por método (media $\pm$ desviación estándar).



Nota. Barras de error corresponden a la desviación estándar sobre 30 réplicas independientes.

Figura 4

Distribución del efecto estimado por método frente al DAG verdadero.



Nota. La línea punteada muestra el efecto estimado con el conjunto de ajuste del verdadero DAG. El algoritmo genético concentra su distribución alrededor de esa referencia, mientras que el PC se mueve sistemáticamente por encima.

3.9 Trabajo futuro previsto

El proyecto tiene cuatro ampliaciones en su continuidad. En primer lugar, la validación en bases de datos reales biomédicas, en que la verdad de fondo es incierta y la evaluación se debe soportar sobre conocimiento experto y la estabilidad del efecto frente a especificaciones alternativas. Segundo, incorporar conocimiento de dominio como restricciones duras y blandas en el operador de mutación, siguiendo la línea de Mao et al. (2025) y Dang et al. (2025), para mejorar la orientación de aristas dentro de la clase de equivalencia. Tercero, la sustitución del score gaussiano por puntajes específicos para datos discretos, un cambio cuya influencia en la estructura recuperada se ha reportado (Yaman & Cengiz, 2025). En cuarto lugar, el levantamiento del supuesto de suficiencia causal mediante grafos ancestrales máximos, a fin de dar lugar a la presencia de confusores latentes.

Referencias bibliográficas

- Bartlett, M., & Cussens, J. (2017). Integer linear programming for the Bayesian network structure learning problem. *Artificial Intelligence*, 244, 258–271.
<https://doi.org/10.1016/j.artint.2015.03.003>
- Behjati, S., & Beigy, H. (2020). Improved K2 algorithm for Bayesian network structure learning. *Engineering Applications of Artificial Intelligence*, 91, 103617.
<https://doi.org/10.1016/j.engappai.2020.103617>
- Beinlich, I. A., Suermondt, H. J., Chavez, R. M., & Cooper, G. F. (1989). The ALARM monitoring system: A case study with two probabilistic inference techniques for belief networks. En J. Hunter, J. Cookson & J. Wyatt (Eds.), *AIME 89* (pp. 247–256). Springer.
https://doi.org/10.1007/978-3-642-93437-7_28
- Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1–C68.
<https://doi.org/10.1111/ectj.12097>
- Chickering, D. M. (2002). Optimal structure identification with greedy search. *Journal of Machine Learning Research*, 3, 507–554.
- Colombo, D., & Maathuis, M. H. (2014). Order-independent constraint-based causal structure learning. *Journal of Machine Learning Research*, 15(1), 3741–3782.
- Constantinou, A. C., Kitson, N. K., Liu, Y., Chobtham, K., Hashemzadeh, A., Nanavati, P. A., Mbuva, R., & Petrungaro, B. (2023). Open problems in causal structure learning: A case study of COVID-19 in the UK. *Expert Systems with Applications*, 234, 121069.
<https://doi.org/10.1016/j.eswa.2023.121069>

- Constantinou, A. C., Liu, Y., Chobtham, K., Guo, Z., & Kitson, N. K. (2021). Large-scale empirical validation of Bayesian network structure learning algorithms with noisy data. *International Journal of Approximate Reasoning*, 131, 151–188. <https://doi.org/10.1016/j.ijar.2021.01.001>
- Dang, Y., Gao, X., & Wang, Z. (2025). A novel hyper-heuristic algorithm with soft and hard constraints for causal discovery using a linear structural equation model. *Entropy*, 27(1), 38. <https://doi.org/10.3390/e27010038>
- Graafland, C. E., & Gutiérrez, J. M. (2022). Learning complex dependency structure of gene regulatory networks from high dimensional microarray data with Gaussian Bayesian networks. *Scientific Reports*, 12, 18704. <https://doi.org/10.1038/s41598-022-21957-z>
- He, C., Di, R., & Tan, X. (2023). Bayesian network structure learning using improved A* with constraints from potential optimal parent sets. *Mathematics*, 11(15), 3344. <https://doi.org/10.3390/math11153344>
- Kitson, N. K., & Constantinou, A. C. (2024). The impact of variable ordering on Bayesian network structure learning. *Data Mining and Knowledge Discovery*, 38(4), 2545–2569. <https://doi.org/10.1007/s10618-024-01044-9>
- Kitson, N. K., Constantinou, A. C., Guo, Z., Liu, Y., & Chobtham, K. (2023). A survey of Bayesian network structure learning. *Artificial Intelligence Review*, 56, 1–94. <https://doi.org/10.1007/s10462-022-10351-w>
- Künzel, S. R., Sekhon, J. S., Bickel, P. J., & Yu, B. (2019). Metalearners for estimating heterogeneous treatment effects using machine learning. *Proceedings of the National Academy of Sciences*, 116(10), 4156–4165. <https://doi.org/10.1073/pnas.1804597116>
- Larrañaga, P., Kuijpers, C. M. H., Murga, R. H., & Yurramendi, Y. (1996a). Learning Bayesian network structures by searching for the best ordering with genetic algorithms. *IEEE*

- Transactions on Systems, Man, and Cybernetics — Part A: Systems and Humans, 26(4), 487–493. <https://doi.org/10.1109/3468.508827>
- Larrañaga, P., Poza, M., Yurramendi, Y., Murga, R. H., & Kuijpers, C. M. H. (1996b). Structure learning of Bayesian networks by genetic algorithms: A performance analysis of control parameters. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 18(9), 912–926. <https://doi.org/10.1109/34.537345>
- Mao, T., Bu, X., Cai, C., Lu, Y., & Du, J. (2025). An improved genetic algorithm for causal discovery. *Journal of Systems Engineering and Electronics*, 36(3), 768–777. <https://doi.org/10.23919/JSEE.2025.000015>
- Pearl, J. (2009). *Causality: Models, reasoning, and inference* (2.^a ed.). Cambridge University Press. <https://doi.org/10.1017/CBO9780511803161>
- Peters, J., Janzing, D., & Schölkopf, B. (2017). *Elements of causal inference: Foundations and learning algorithms*. MIT Press.
- Reisach, A. G., Seiler, C., & Weichwald, S. (2021). Beware of the simulated DAG! Causal discovery benchmarks may be easy to game. *Advances in Neural Information Processing Systems*, 34, 27772–27784.
- Robinson, R. W. (1977). Counting unlabeled acyclic digraphs. En C. H. C. Little (Ed.), *Combinatorial Mathematics V* (pp. 28–43). Springer. <https://doi.org/10.1007/BFb0069178>
- Sandoval-Álvarez, C. (2025). Exploración de los efectos indirectos condicionales: Un enfoque de modelado de ecuaciones estructurales. *Revista de Administração Contemporânea*, 29(4), e250047. <https://doi.org/10.1590/1982-7849rac2025250047.en>

- Scanagatta, M., Salmerón, A., & Stella, F. (2019). A survey on Bayesian network structure learning from data. *Progress in Artificial Intelligence*, 8, 425–439. <https://doi.org/10.1007/s13748-019-00194-y>
- Scutari, M. (2010). Learning Bayesian networks with the bnlearn R package. *Journal of Statistical Software*, 35(3), 1–22. <https://doi.org/10.18637/jss.v035.i03>
- Scutari, M., Graafland, C. E., & Gutiérrez, J. M. (2019). Who learns better Bayesian network structures: Accuracy and speed of structure learning algorithms. *International Journal of Approximate Reasoning*, 115, 235–253. <https://doi.org/10.1016/j.ijar.2019.10.003>
- Sharma, A., & Kiciman, E. (2020). DoWhy: An end-to-end library for causal inference. *arXiv*. <https://doi.org/10.48550/arXiv.2011.04216>
- Spirtes, P., Glymour, C., & Scheines, R. (2000). *Causation, prediction, and search* (2.^a ed.). MIT Press.
- Sun, B., & Zhou, Y. (2022). Bayesian network structure learning with improved genetic algorithm. *International Journal of Intelligent Systems*, 37(9), 6023–6047. <https://doi.org/10.1002/int.22833>
- Trinchera, L., Pietropolli, G., Castelli, M., & Schuberth, F. (2026). Automated specification search for composite-based structural equation modeling: A genetic approach. *Computational Statistics & Data Analysis*, 219, 108348. <https://doi.org/10.1016/j.csda.2026.108348>
- Tsamardinos, I., Brown, L. E., & Aliferis, C. F. (2006). The max-min hill-climbing Bayesian network structure learning algorithm. *Machine Learning*, 65(1), 31–78. <https://doi.org/10.1007/s10994-006-6889-7>

- Vowels, M. J., Camgoz, N. C., & Bowden, R. (2022). D'ya like DAGs? A survey on structure learning and causal discovery. *ACM Computing Surveys*, 55(4), 82. <https://doi.org/10.1145/3527154>
- Wager, S., & Athey, S. (2018). Estimation and inference of heterogeneous treatment effects using random forests. *Journal of the American Statistical Association*, 113(523), 1228–1242. <https://doi.org/10.1080/01621459.2017.1319839>
- Yaman, A., & Cengiz, M. A. (2025). Comparative evaluation of score criteria for dynamic Bayesian network structure learning. *PLOS ONE*, 20(11), e0336250. <https://doi.org/10.1371/journal.pone.0336250>
- Zheng, X., Aragam, B., Ravikumar, P., & Xing, E. P. (2018). DAGs with NO TEARS: Continuous optimization for structure learning. *Advances in Neural Information Processing Systems*, 31, 9472–9483. <https://doi.org/10.48550/arXiv.1803.01422>

Anexos

Anexo A. Disponibilidad del código y de los datos.

El código fuente completo, limpio, documentado y acompañado de pruebas automatizadas se entrega como repositorio público bajo licencia MIT, en la carpeta causal-ga-dml. Incluye el paquete modular (src/causal_ga_dml), las configuraciones de los experimentos (configs), los guiones de ejecución (scripts), la batería de 35 pruebas (tests) y la documentación de reproducibilidad (docs/REPRODUCIBILITY.md), de la formalización metodológica (docs/METHODS.md) y de publicación (docs/GITHUB.md). El experimento completo se reproduce con la instrucción `make all`; una corrida única de verificación toma aproximadamente 30 segundos. La red ALARM se obtiene programáticamente de la biblioteca `pgmpy`, por lo que no se requiere descargar datos externos.